TD1 — Rapport

valant évaluation dans le cadre de :

Diplôme : Master SEP
Année universitaire : 2026-2027
Module d'enseignement : Ingénierie des données massives
Responsable : Ouael ETTOUILEB
Comptant pour : notebook et rapport évalués ensemble sur 20 points

Pipeline ETL de la fréquentation du réseau ferré francilien : Bronze sur Cloud Storage, Silver et Gold sur BigQuery

ADJAKOSSA et AKODEKOU

Métriques

Finalisé le : 1 novembre 2026
Page(s) : 13
Références(s) : –
Figure(s) : –
Table(s) : –
Théorème(s) : 0

Résumé : Ce rapport présente un pipeline rejouable qui prépare trois années civiles complètes (2023 à 2025) de validations du réseau ferré d'Île-de-France, enrichies par le référentiel des zones de correspondance, les jours fériés et la météo quotidienne. Les 23 fichiers sources sont conservés dans Cloud Storage en snapshots immuables, avec provenance et empreinte SHA-256. La couche Silver résout l'hétérogénéité des neuf fichiers de validations (quatre encodages, trois formats de date, deux nomenclatures de titres) sans perdre une ligne : 5 635 554 lignes et 5 790 213 667 validations sont conservées à l'unité jusqu'au Gold. Le modèle Gold sert trois publics ; 99,49 % du volume est rattaché à une zone et à une station météo située à 3,9 km en médiane. Une seconde exécution reproduit à l'identique les objets Bronze et toutes les tables.

Mots-clés : Architecture médaillon, BigQuery, Cloud Storage, Qualité des données, Rejouabilité, Île-de-France Mobilités

Matériel supplémentaire :
git : github.com/rveadja-max/TD1_IDFM (branche dev)
: Projet GCP td-v1-511114 ; bucket td-v1-511114-td1-idfm ; datasets silver_idfm et gold_idfm (EU) ; snapshot Bronze 2026-10-31

Table des matières

Sigles et conventions **3**

Introduction **4**

1 Architecture et méthode **4**
1.1 Architecture médaillon . . . 4
1.2 Choix de stockage . . . 4
1.3 Principes de rejouabilité . . . 4

2 Collecte et transformations des quatre sources **5**
2.1 Bronze : 23 objets, 153 Mo . . . 5
2.2 Validations : neuf fichiers, neuf formats . . . 5
2.3 Zones, jours fériés et météo . . . 6

3 Modèle Gold **6**
3.1 Tables et granularités . . . 6
3.2 Choix de conception . . . 7

4 Contrôles et résultats chiffrés **7**

5 Exemples d'exploitation **8**
5.1 Data Scientist : variables explicatives . . . 8
5.2 Data Analyst : indicateurs . . . 8
5.3 Agent IA (facultatif) . . . 9

6 Anomalies, limites et fiabilité **9**
6.1 Limites connues . . . 9
6.2 Notes de fiabilité des tables Gold . . . 9

7 Usage de l'IA **10**

8 Apprentissages du binôme **10**

Annexe A : liste des contrôles **11**

Annexe B : scripts versionnés **12**

Bibliographie **13**

Sigles et conventions

Tableau 1 – Sigles et conventions

Terme	Sens dans ce rapport
IDFM	Île-de-France Mobilités, producteur des validations et des zones
GCS, BQ	Google Cloud Storage, BigQuery
ZdC	zone de correspondance : arrêts proches reliés à pied (`ZdCId`)
Validation	passage d'un titre en entrée de station ; **ce n'est pas un voyageur unique**
Jour d'exploitation	de 04 h 00 à 03 h 59 le lendemain (champ `JOUR`)
Snapshot	ensemble figé des fichiers sources collectés sous une même date (`2026-10-31`)
Station éligible	station météo dont TM et RR sont exploitables sur au moins 95 % des jours de la période
Non précisé	information absente des sources consultées ; elle n'est pas déduite

Introduction

Le sujet demande de préparer, sur Google Cloud, des données de fréquentation du réseau ferré francilien utilisables par un Data Scientist, un Data Analyst et un agent IA. Le travail porte sur la préparation des données : ni modèle, ni tableau de bord, ni agent ne sont développés. Quatre sources sont imposées (*TD1 – ETL des données de fréquentation IDFM sur GCS et BigQuery* 2026 ; *TD1 – Données sources* 2026) : les validations quotidiennes IDFM, le référentiel des zones de correspondance, les jours fériés de la zone métropole et la météo quotidienne de Météo-France.

La question directrice est la suivante : **comment livrer, à partir de fichiers publics hétérogènes, un modèle analytique dont chaque chiffre peut être retracé jusqu'à l'octet source, et qui donne le même résultat à chaque exécution ?** Le rapport décrit l'architecture (partie 1), les transformations des quatre sources (partie 2), le modèle Gold (partie 3), les contrôles et leurs résultats (partie 4), les exemples d'exploitation (partie 5), puis discute les limites, la fiabilité des tables, l'usage de l'IA et les apprentissages (parties 6 à 8).

Tous les chiffres cités proviennent de l'exécution du pipeline sur le snapshot du 31 octobre 2026 et sont reproduits par le notebook `TD1_ADJAKOSSA_AKODEKOU.ipynb`.

1. Architecture et méthode

1.1. Architecture médaillon

Couche	Support	Rôle et règle principale
Bronze	GCS, `bronze/<source>/snapshot=<date>/<partition>/`	octets d'origine, jamais modifiés ni écrasés ; manifeste de provenance et SHA-256 par objet
Silver	BigQuery `silver_idfm`	une table de chargement par source (schéma explicite, remplacement), puis une table finale typée et documentée ; anomalies quantifiées, jamais masquées
Gold	BigQuery `gold_idfm`	dimensions, faits, variables et vues KPI ; clés de dimension uniques vérifiées avant jointure
Contrôles	`sql/checks/`	une ligne par contrôle : mesure, attendu, statut, interprétation

Le code est séparé par responsabilité : `src/collect/` (appels HTTP, validation des réponses), `src/bronze/` (chemins, dépôt, manifestes), `src/silver/` (normalisation et chargement), `sql/silver/` et `sql/gold/` (transformations versionnées), `src/quality/` et `sql/checks/` (contrôles et empreintes). Le notebook n'appelle que ces fonctions ; il est le point d'entrée manuel, sans orchestration. L'exécution est locale (Ubuntu 24.04 sous WSL2) avec les identifiants par défaut de Google (ADC) ; aucun identifiant de projet n'est écrit dans le code, tout est lu dans `.env`. Chaque requête BigQuery est plafonnée à 10 Go facturés.

1.2. Choix de stockage

Deux skills Google (`google-cloud-storage-basics`, `bigquery-optimization`) ont servi à auditer la configuration.

— **Cloud Storage.** Le bucket est en région EU, avec accès uniforme, accès public bloqué et suppression réversible pendant 7 jours (*soft delete*). En plus de la précondition de création, chaque objet Bronze et son manifeste portent un **hold temporaire** : tant qu'il est posé, GCS refuse toute suppression ou tout remplacement, quel que soit l'outil ; les 46 objets en sont dotés. Un verrouillage du bucket (*Bucket Lock*) a été écarté : il est irréversible et aurait bloqué le préfixe `silver_staging/`, que le pipeline remplace volontairement.

— **BigQuery.** Les tables étaient d'abord partitionnées par jour. L'audit a mesuré des partitions de 0,4 à 0,8 Mo, très loin des quelque 10 Go recommandés, et environ 2 100 secondes de slot pour construire `validations` comme `fait_validations_jour`. Aucune table n'est désormais partitionnée ; un clustering par jour, zone et catégorie suffit à l'élagage des blocs. Le temps de calcul tombe à 74 et 118 secondes de slot, à contenu identique (empreintes égales). Toute la session a facturé 97 Go de requêtes, soit environ 0,55 USD au tarif public à la demande.

1.3. Principes de rejouabilité

1. **Bronze immuable.** Un objet est créé avec la précondition `if_generation_match=0` (Google Cloud 2026b) : GCS refuse d'écraser un objet existant. À la relance, l'objet existant est réutilisé **sans recontacter la source**, et son SHA-256 est recalculé puis comparé au manifeste.
2. **Actualisation explicite.** Une nouvelle collecte exige une nouvelle `SNAPSHOT_DATE`, donc de nouveaux chemins ; l'ancien snapshot reste intact.
3. **Silver et Gold déterministes.** Les tables de chargement sont écrites en `WRITE_TRUNCATE` et toutes les tables finales en `CREATE OR REPLACE`, exclusivement à partir de Bronze : aucune relance ne peut ajouter de lignes.

2. Collecte et transformations des quatre sources

2.1. Bronze : 23 objets, 153 Mo

Les URL des fichiers ne sont pas figées : elles sont lues dans les catalogues officiels (API IDFM pour l'archive annuelle des validations (Île-de-France Mobilités 2026b), API data.gouv.fr pour les fichiers météo (Météo-France 2026b)) ; les zones (Île-de-France Mobilités 2026c) et les jours fériés (Etalab 2026) sont exportés directement. Avant tout dépôt, le contenu est validé : relecture complète et CRC des archives ZIP, décompression complète et en-tête des GZIP, schéma du Parquet, dates du JSON des jours fériés. Les erreurs HTTP définitives arrêtent la collecte ; les codes transitoires (429, 5xx) et les délais dépassés déclenchent quatre essais avec attente croissante ; une réponse vide est refusée.

Tableau 2 – Objets Bronze du snapshot 2026-10-31

Source	Objets	Octets	Partition
Validations IDFM (archives ZIP annuelles)	3	113 792 398	`annee=`
Zones de correspondance (export Parquet)	1	740 290	—
Jours fériés métropole (JSON)	3	954	`annee=`
Météo RR-T-Vent, 8 départements × 2 périodes (CSV GZIP)	16	38 371 735	`departement=`

Chaque objet est accompagné de `<objet>.manifest.json` (URL demandée et finale, paramètres, horodatage UTC, taille, SHA-256, statut HTTP, type de contenu) ; les mêmes informations sont portées par les métadonnées GCS de l'objet.

2.2. Validations : neuf fichiers, neuf formats

L'exploration a précédé toute définition de schéma. Elle révèle que les archives annuelles ne sont pas homogènes (tableau 3).

Tableau 3 – Hétérogénéité des fichiers de validations

Fichier	Lignes	Particularités constatées
2023 S1 (TXT)	1 096 209	cp1252 ; colonne `lda` au lieu de `ID_ZDC` ; ancienne nomenclature des titres ; espace dans le nom de fichier ; `NB_VALD` minimal = 5
2023 S2 (TXT)	849 596	encodage UTF-16 avec marque d'ordre
2024 S1 (TXT)	859 043	cp1252 ; dates `JJ/MM/AAAA`
2024 T3 (TXT)	466 121	UTF-8 ; dates `JJ/MM/AA` ; séparateurs de milliers dans `NB_VALD` (« 1 020 »)
2024 T4 (TXT)	472 132	dates ISO ; `ID_ZDC` décimal (« 71379.0 »)
2025 T1 à T4 (XLSX)	1 892 453	en-tête `Date` (T2), `ID_ZdC` (T1), ordre des colonnes permuté (T3, T4), « Solidarite » sans accent (T4)

Normalisation technique (Python). Chaque fichier est décodé selon sa marque d'ordre ou par essai strict (UTF-16, puis UTF-8, sinon cp1252), lu en texte, et ses colonnes sont repérées **par leur nom** à l'aide d'une table d'alias (`Date` → `JOUR`, `lda` → `ID_ZDC`). Aucune valeur n'est modifiée ; le fichier et le numéro de ligne d'origine sont ajoutés. Le résultat est chargé dans `validations_chargement` avec un schéma explicite entièrement en `STRING` : 5 635 554 lignes, soit exactement la somme des neuf fichiers.

Transformations Silver (SQL, `sql/silver/03_validations.sql`).

- *Dates* : le format est choisi par motif (`AAAA-MM-JJ`, `JJ/MM/AAAA`, `JJ/MM/AA`), jamais deviné ; chaque date est ensuite confrontée à la période annoncée par le nom du fichier.
- *Mesure* : retrait des espaces, y compris insécables, puis conversion entière.
- *Codes* : `CODE_STIF_TRNS`, `CODE_STIF_RES`, `CODE_STIF_ARRET` et `ID_ZDC` restent du texte ; seul l'artefact décimal « .0 » est retiré. La valeur `ND` est traitée comme absente.
- *Arrêts non déterminés* : les lignes « Inconnu » (code `ND` ou vide, `ID_ZDC` = 999999) sont conservées, car elles comptent dans le total du réseau, avec l'indicateur `arret_non_determine`.
- *Zones* : quand la zone publiée est absente ou hors du référentiel actuel, la zone utilisée pour le même arrêt (transporteur, réseau, code et libellé) est reprise, **uniquement si elle est unique et référencée**. La zone publiée reste dans `id_zdc_source` et l'origine dans `origine_id_zdc`.

— *Catégories* : la table `ref_categorie_titre` relie l'ancienne nomenclature à la nouvelle avec un niveau de correspondance, établi à partir des définitions de la documentation IDFM (Île-de-France Mobilités 2026a) (tableau 4).
— *Censure* : la documentation IDFM indique que `NB_VALD = 5` signifie « 5 validations ou moins » dans l'ancienne codification ; les fichiers concernés sont repérés par leur minimum égal à 5 et les valeurs marquées `nb_vald_plancher_5`.
— *Rejets* : une ligne illisible serait écartée dans `validations_rejets` avec son motif ; après traitement des sentinelles, **aucune ligne n'est rejetée**.

Tableau 4 – Harmonisation des catégories de titres

Niveau	Catégories sources	Part du volume
identique	nouvelle nomenclature (7 libellés)	84,46 %
variante orthographique	`IMAGINE R`, `AMETHYSTE`, « Solidarite » sans accent	4,48 %
probable	`NAVIGO` → Forfait Navigo, `TST` → Contrat Solidarité Transport, `AUTRE TITRE` → Autres titres	10,21 %
non établie (conservée à part)	`NAVIGO JOUR`, `FGT`, « ? »	0,85 %

La table finale `validations` est regroupée (clustering) par jour, zone et catégorie ; son schéma, avec une description par colonne, est déclaré dans le script.

2.3. Zones, jours fériés et météo

Zones. Le Parquet Bronze est chargé tel quel (schéma embarqué), puis les coordonnées Lambert 93 (EPSG :2154) sont converties en WGS84 avec `pyproj` (pyproj contributors s. d.) ; elles ne sont jamais lues comme des degrés. La table `zones_correspondance` (15 597 zones) garde les deux systèmes et un point `GEOGRAPHY`. Le code INSEE est conservé en texte : ce n'est pas un code postal. Le référentiel est **actuel** : il ne décrit pas les zones supprimées avant le snapshot.

Jours fériés. Le JSON `{date: nom}` de chaque année est converti en lignes puis chargé avec un schéma explicite ; la table `jours_feries` compte 11 dates distinctes par an.

Météo. Les 16 fichiers RR-T-Vent sont lus **directement depuis Bronze** par une table externe BigQuery (Google Cloud 2026a) au schéma explicite de 60 colonnes (en-tête vérifié identique dans tous les fichiers) ; la pseudo-colonne `_FILE_NAME` conserve le fichier d'origine de chaque ligne. `NUM_POSTE` reste du texte. Les codes qualité sont appliqués selon le descriptif Météo-France (Météo-France 2026a) : une valeur est retenue si son code vaut 0 (protégée), 1 (validée) ou 9 (filtrée), et mise à `NULL` si elle vaut 2 (douteuse) ; la valeur brute reste disponible. Sur 2023–2025, la table compte 52 180 lignes pour 50 stations.

3. Modèle Gold

3.1. Tables et granularités

Table / vue	Public	Grain (une ligne)	Clé ; mesures et règles
`dim_date`	tous	un jour 2023–2025	`jour` ; type de jour (Férié > Dimanche > Samedi > Ouvré), pont
`dim_zone`	tous	une zone du référentiel	`zdc_id` ; station éligible la plus proche, distance
`meteo_station_jour`	DS	station éligible × jour	`num_poste, jour` ; RR, TN, TX, TM retenus
`meteo_jour_idf`	DA, DS	un jour	`jour` ; moyennes des stations éligibles
`fait_validations_jour`	socle	jour × zone × catégorie	`nb_vald` additif ; `nb_arrets` non additif
`ds_zone_jour`	DS	zone × jour (grille)	retards J-1, J-7, J-364 ; moyennes 7 et 28 jours
`v_kpi_*` (4 vues)	DA	selon la vue	totaux, moyennes par type de jour, parts, rangs
`regles_mesures`, `v_catalogue_colonnes`	agent IA	une règle, une colonne	définitions, agrégations permises, limites

Relations. `fait_validations_jour` est en relation N–1 avec `dim_date` (`jour`) et avec `dim_zone` (`zdc_id`, qui peut être nul) ; `dim_zone` est en relation N–1 avec la station de référence (`num_poste_ref`). La table de faits est obtenue par **agrégation des validations Silver avant toute jointure**, ce qui exclut toute multiplication de lignes ; les dimensions sont ensuite jointes sur des clés dont l'unicité est contrôlée.

3.2. Choix de conception

— **Grain du fait.** Le grain publié (jour × transporteur × réseau × arrêt × catégorie) n'est pas unique (partie 4) ; la zone de correspondance est la plus petite unité spatiale fiable et correspond à l'usage demandé (« fréquentation par zone »). Le détail par arrêt reste en Silver.
— **Rattachement météo.** Les coordonnées le permettent : chaque zone est reliée à la station éligible la plus proche (distance géodésique `ST_DISTANCE`, départage par `num_poste`). Seules les 44 stations sur 50 dont TM et RR sont exploitables sur au moins 95 % des jours sont éligibles, afin qu'une zone ne reçoive pas une série lacunaire. En l'absence de mesure de la station un jour donné, `ds_zone_jour` prend la moyenne régionale et l'indique dans `source_meteo`.
— **Variables temporelles.** Les retards sont joints **sur la date** (et non par décalage de lignes) : J-7 désigne la date d'il y a sept jours même si un jour manque. Les moyennes glissantes portent sur les jours **précédents** seulement, ce qui évite d'introduire la cible dans ses propres variables. Un jour sans ligne publiée garde `nb_vald` nul au sens SQL (`NULL`) et `jour_observe = FALSE` : l'absence n'est pas transformée en zéro.
— **Agent IA.** Les descriptions de colonnes sont déclarées dans les schémas et exposées par `v_catalogue_colonnes` ; `regles_mesures` énonce en clair les définitions, les agrégations permises et les pièges (validation voyageur, décalage horaire de RR, nomenclatures).

4. Contrôles et résultats chiffrés

Cinquante-trois contrôles reproductibles sont exécutés par le notebook (`sql/checks/`) : 27 conformes, 23 informatifs (mesures sans seuil) et 3 à examiner, tous expliqués ci-dessous. Le tableau 5 en présente l'essentiel ; la liste complète figure en annexe A.

Tableau 5 – Principaux contrôles (exécution du snapshot 2026-10-31)

Contrôle	Mesure	Statut
Lignes : chargement = Silver + rejets	5 635 554 = 5 635 554 + 0	conforme
Somme `NB_VALD` : chargement = Silver + rejets	5 790 213 667 = 5 790 213 667 + 0	conforme
Jours présents 2023 / 2024 / 2025	365/365, 366/366, 365/365	conforme
`NB_VALD` négatives ou nulles	0	conforme
Codes non numériques (hors sentinelles)	0	conforme
Clé publiée (jour × trns × rés × arrêt × catégorie)	22 792 groupes non uniques	expliqué
Clé étendue (+ libellé + zone publiée)	644 groupes, tous Porte de Clichy 2025 T4	expliqué
Unicité `zdc_id`, station × jour, dates fériées	15 597 / 15 597 ; 52 180 / 52 180 ; 11 par an	conforme
Incohérences météo (TN > TX, RR < 0, hors [-25 ; 45] °C)	0	conforme
Unicité des clés `dim_date`, `dim_zone`, grains Gold	1 096 ; 15 597 ; 5 327 245 ; 819 808	conforme
Silver → fait : lignes et `NB_VALD`	5 635 554 → 5 635 554 ; 5 790 213 667 → idem	conforme
Validations sans zone référencée	0,694 % des lignes ; 0,515 % du volume	expliqué
Météo de la station de référence dans `ds_zone_jour`	819 250 / 819 808 zone-jours ; 558 en repli	conforme

Grain publié non unique. Un même code d'arrêt couvre plusieurs arrêts distincts : par exemple, le code 48092 du tram T13 désigne *Camp des Loges* et *Lisière Pereire*, deux zones différentes. Avec le libellé et la zone, la clé devient unique, sauf pour Porte de Clichy en 2025 T4, publiée sur deux lignes de valeurs différentes par catégorie et par jour. La somme de ces deux lignes (26 199 validations par jour) prolonge la tendance des trimestres précédents (22 839 en 2024 T4, 24 565 en 2025 T2), alors qu'une duplication aurait donné le double : ces lignes sont complémentaires, elles sont conservées et sommées.

Bilan des jointures. La jointure des validations à `dim_zone` est une jointure externe sur une clé unique : lignes et volume sont identiques avant et après. Avant la règle de reprise des zones, 3,16 % du volume ne trouvait pas de zone : jusqu'en 2025 T1, de grandes gares (Montparnasse 74040, La Chapelle 74000, Bastille 71743, Juvisy 62737…) sont publiées sous un ancien identifiant absent du référentiel actuel, alors que le même arrêt porte l'identifiant actuel à partir de 2025 T2 (non-correspondance par fichier : 3,7 à 4,7 % jusqu'en 2025 T1, environ 0,5 % ensuite). Après reprise, la non-correspondance tombe à 0,515 % du volume, composé des arrêts non déterminés (0,022 %) et d'identifiants hors référentiel sans équivalent unique (0,493 %). Ces lignes restent dans le fait (`zone_referencee = FALSE`) et dans les totaux du réseau.

Les trois contrôles « à examiner ». V04b est expliqué plus haut (Porte de Clichy). V10 compare, pour un même arrêt et un même libellé, la colonne `lda` de 2023 S1 et `ID_ZDC` de 2023 S2 : 756 arrêts sur 759 portent la même valeur, ce qui justifie de lire `lda` comme une zone ; les trois écarts sont traités par la règle de reprise des zones. Z03 relève 22 zones situées à Dreux, présentes dans le référentiel source.

Rejouabilité. Le notebook calcule, pour 15 tables Silver et Gold, le nombre de lignes et une empreinte de contenu indépendante de l'ordre des lignes (XOR des `FARM_FINGERPRINT` des lignes sérialisées en JSON), relance l'intégralité du pipeline avec les mêmes paramètres et le même snapshot, puis compare. Résultat : **15 tables sur 15 ont le même nombre de**

lignes et le même contenu ; côté Bronze, les 23 objets sont réutilisés sans nouvel appel aux sources et leurs SHA-256 sont identiques. Cette démonstration a d'abord échoué sur `meteo_jour_idf` et `ds_zone_jour` : des moyennes en virgule flottante (`AVG` sur `FLOAT64`) varient au dernier chiffre selon l'ordre d'addition, que BigQuery ne garantit pas. Le calcul en `NUMERIC` (décimal exact) a supprimé cet écart, vérifié ensuite par trois relances successives identiques.

5. Exemples d'exploitation

5.1. Data Scientist : variables explicatives

`ds_zone_jour` compte 819 808 lignes : 748 zones × 1 096 jours, dont 97,03 % de jours observés. Pour chaque zone et chaque jour, il fournit la cible, le calendrier, la météo de la station de référence et les variables retardées. Pour illustrer leur usage, l'écart relatif à la moyenne glissante sur 28 jours a été calculé pour les jours ouvrés (zones d'au moins 500 validations par jour en moyenne) : +17,58 % les jours secs (305 772 zone-jours) et +19,30 % les jours pluvieux (RR 1 mm, 132 240 zone-jours). L'écart est positif dans les deux cas parce que la moyenne glissante inclut les fins de semaine. La différence entre jours secs et pluvieux est descriptive : elle ne tient compte ni de la saison ni du jour de la semaine et ne constitue pas un effet causal.

5.2. Data Analyst : indicateurs

Tableau 6 – Volume annuel et indice des types de jour (base 100 = jour ouvré moyen de l'année)

Année	Validations	Moyenne / jour	Samedi	Dimanche	Férié
2023	1 726 555 186	4 730 288	66,9	45,3	45,6
2024	1 905 998 830	5 207 647	69,6	48,4	46,1
2025	2 157 659 651	5 911 396	73,9	52,2	52,0

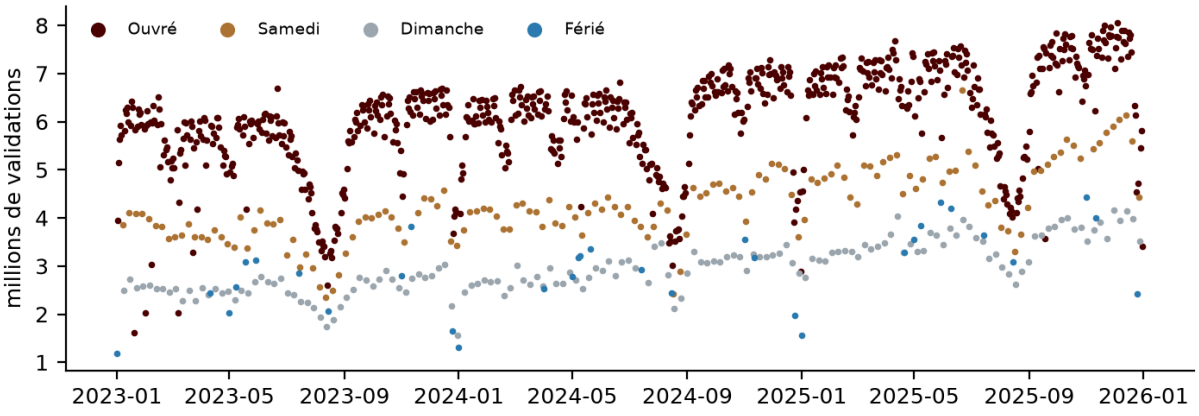


Figure 1 – Validations quotidiennes du réseau ferré selon le type de jour

Les fins de semaine et les jours fériés se rapprochent du jour ouvré d'une année sur l'autre (tableau 6). La hausse du volume annuel (+25 % entre 2023 et 2025) doit être lue avec prudence : le nombre d'arrêts publiés varie aussi (781 en 2023, 808 en 2025), et la part due à la fréquentation et celle due au périmètre de collecte ne sont pas séparables avec ces seules données. En 2025, les cinq premières zones sont Gare Saint-Lazare (82,6 millions de validations), La Défense, Châtelet, Gare de Lyon et Gare Montparnasse.

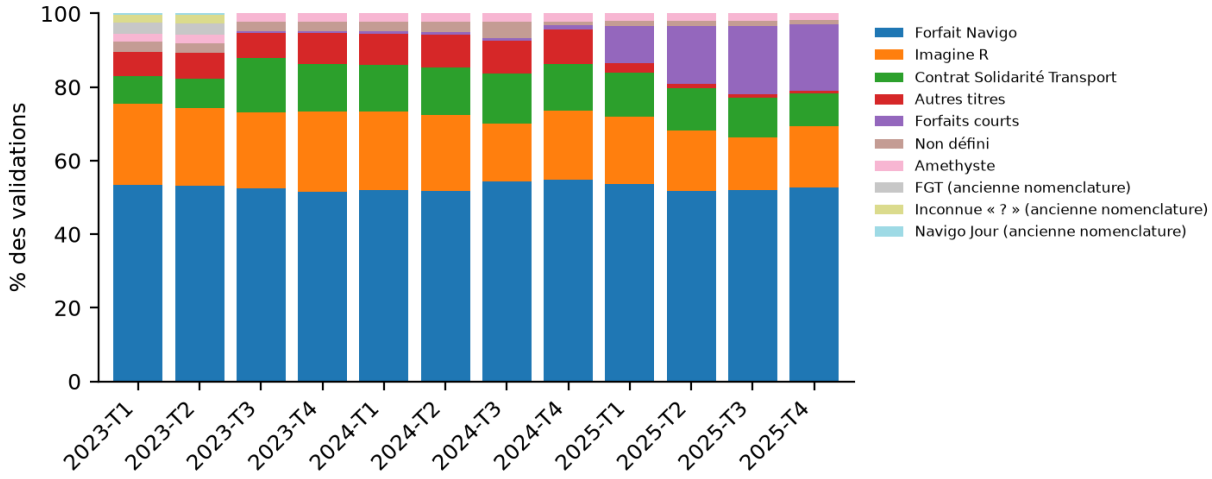


FIGURE 2 – Part trimestrielle des catégories de titres harmonisées

La figure 2 montre deux ruptures de classement. La première, en juillet 2023, correspond au changement de nomenclature traité en Silver. La seconde, en 2025 T1, a lieu à l'intérieur de la nouvelle nomenclature : « Forfaits courts » passe d'environ 1 % à 10 puis 18 % du volume, tandis qu'« Autres titres » tombe de 9 % à moins de 3 %. Les sources ne documentent pas la cause de ce reclassement ; ces deux catégories ne doivent pas être comparées de part et d'autre de janvier 2025 ; cette règle est inscrite dans `regles_mesures`.

5.3. Agent IA (facultatif)

Un agent qui interroge le Gold dispose de `regles_mesures` (douze règles : définitions, agrégations permises, limites) et de `v_catalogue_colonnes`, qui expose la description de chaque colonne. Il peut ainsi répondre que `nb_vald` se somme mais ne compte pas des voyageurs, ou que les catégories d'avant juillet 2023 reposent en partie sur une correspondance probable.

6. Anomalies, limites et fiabilité

6.1. Limites connues

- **Validations voyageurs** : une personne peut valider plusieurs fois ; les sorties ne sont pas comptées.
- **Référentiel des zones actuel** : 0,5 % du volume reste sans zone ; les identifiants anciens ne sont remplacés que lorsque l'équivalence est unique.
- **Nomenclatures de titres** : correspondance probable pour 10,21 % du volume, absente pour 0,85 % (2023 S1) ; reclassement non documenté en 2025 T1.
- **Censure « 5 ou moins »** en 2023 S1 : 111 917 lignes, 0,010 % du volume.
- **Météo** : RR couvre de 06 h UTC à 06 h UTC le lendemain, ce qui est décalé par rapport au jour d'exploitation (04 h–03 h 59) ; la station de référence est à 3,9 km en médiane (23,9 km au plus).
- **Calendrier** : vacances scolaires, grèves et événements ne sont pas couverts, faute de source.
- **Référentiel au-delà de l'Île-de-France** : 22 zones situées à Dreux (Eure-et-Loir) ; elles existent dans la source et ne résultent pas d'une erreur de conversion.

6.2. Notes de fiabilité des tables Gold

TABLEAU 7 – Notes de fiabilité, argumentées par les contrôles de la partie 4

Table	Note	Justification
`dim_date`	9,5/10	complète (1 096 jours), fériés officiels contrôlés ; vacances scolaires absentes
`dim_zone`	8/10	clé unique, coordonnées converties et contrôlées ; référentiel actuel, non historisé
`meteo_station_jour`	8,5/10	stations couvertes à au moins 95 %, codes qualité appliqués, aucune incohérence ; décalage horaire de RR

Table	Note	Justification
`meteo_jour_idf`	8/10	moyenne simple, sans pondération spatiale ; utile en repli et au niveau du réseau
`fait_validations_jour`	8,5/10	volumes conservés à l'unité, 99,49 % du volume localisé ; nomenclatures non comparables avant juillet 2023 et autour de janvier 2025
`ds_zone_jour`	8/10	grain unique, pas de fuite de la cible, météo de station pour 99,93 % des zone-jours ; hérite des limites du fait
Vues KPI	8/10	calculées sur le fait contrôlé ; évolutions par zone sensibles aux changements d'identifiants

7. Usage de l'IA

L'assistant Claude Code (modèle Claude Opus), complété par des *skills* (instructions spécialisées, dont deux skills Google pour Cloud Storage et l'optimisation BigQuery), a été utilisé dans le terminal, sur le dépôt local, pour l'ensemble du travail : diagnostic de l'existant, exploration des sources, écriture du code Python et SQL, des tests, du notebook et d'une première version de ce rapport. Le binôme a fixé le périmètre, validé les créations de ressources payantes (bucket, datasets) et arbitré les choix. Un fichier `CLAUDE.md` imposait des règles explicites : ne rien inventer, contrôler par requête, quantifier les anomalies, travailler par petites étapes vérifiables.

Évaluation des résultats. Aucune affirmation n'a été acceptée sans mesure : chaque hypothèse de l'IA a été confrontée à une requête. Plusieurs erreurs ont ainsi été détectées et corrigées :

- lecture des dates de l'exploration avec l'option « jour en premier » appliquée aux dates ISO, qui transformait `2024-10-01` en 10 janvier ; corrigée par un choix de format selon le motif ;
- échappement des apostrophes à la manière SQL standard (`''`), refusé par BigQuery ;
- condition `NULL IN (…)`, qui excluait silencieusement les zones absentes de la règle de reprise ; révélée par la hausse inattendue des lignes « absentes » et corrigée par `IFNULL` ;
- première hypothèse de « doublons » sur 22 792 groupes, infirmée par l'analyse : il s'agissait de codes d'arrêt partagés ;
- erreur 403 « billing account disabled », due au projet de facturation des identifiants locaux (un autre projet, sans facturation) ; diagnostiquée puis corrigée par `gcloud auth application-default set-quota-project` ;
- moyennes en virgule flottante (`AVG` sur `FLOAT64`) dont le dernier chiffre dépend de l'ordre d'addition : la première démonstration de rejouabilité a échoué sur `meteo_jour_idf` et `ds_zone_jour`, détecté par la comparaison des empreintes ; corrigé par un calcul en `NUMERIC` exact, puis vérifié par trois relances successives identiques ;
- une opération Git de l'assistant a supprimé du disque des fichiers locaux en les retirant du suivi ; ils ont été restaurés depuis l'historique.

L'IA a accéléré l'écriture du code répétitif et l'exploration des formats. Elle a aussi produit des erreurs plausibles, que seuls les contrôles chiffrés ont permis de repérer.

8. Apprentissages du binôme

1. **Explorer avant de typer.** Les neuf fichiers de validations ont révélé quatre encodages et trois formats de date : un schéma fixé à partir de la documentation aurait échoué ou, pire, produit des dates fausses sans erreur.
2. **Une clé déclarée n'est pas une clé vérifiée.** Le grain annoncé par la source n'est pas unique ; seule une requête l'a montré.
3. **Mesurer avant et après chaque jointure.** Le taux de non-correspondance a fait apparaître le problème des identifiants de zone anciens, invisible autrement.
4. **Ne pas transformer une absence en valeur.** Les jours sans ligne, les sentinelles et les catégories sans équivalent sont conservés et signalés plutôt que remplacés.
5. **La rejouabilité se conçoit dès Bronze** : snapshots immuables, remplacement des tables et empreintes de contenu.

Annexe A : liste des contrôles

Tableau 8 – Résultats des contrôles, exécution du snapshot 2026-10-31

Id	Contrôle	Mesure	Statut
V01	Conservation des lignes : chargement = Silver + rejets	5635554 = 5635554 + 0	conforme
V02	Conservation de la somme NB_VALD lisible	5790213667 = 5790213667 + 0	conforme
V03	Lignes rejetées	0 lignes, 0 validations	conforme
V04	Unicité de la clé jour × transporteur × réseau × arrêt × catégorie source	22792 groupes en doublon (6486602 validations)	information
V04b	Unicité de la clé étendue (+ libellé + ID_ZDC publié)	644 groupes en doublon : PTE DE CLICHY (2025_T4_NB_FER.xlsx)	à examiner
V05	Jours présents en 2023	365 / 365	conforme
V05	Jours présents en 2024	366 / 366	conforme
V05	Jours présents en 2025	365 / 365	conforme
V06	Valeurs NB_VALD négatives ou nulles	0 négatives, 0 nulles	conforme
V07	Codes transporteur, réseau ou arrêt non numériques	0 lignes	conforme
V08	Origine de la zone : absente	5511 lignes, 0.0217 % des validations	information
V08	Origine de la zone : complétée (même arrêt, autres lignes)	3485 lignes, 0.0850 % des validations	information
V08	Origine de la zone : remplacée (ancien identifiant hors référentiel)	79205 lignes, 2.6412 % des validations	information
V08	Origine de la zone : source	5513769 lignes, 96.7592 % des validations	information
V08	Origine de la zone : source hors référentiel	33584 lignes, 0.4929 % des validations	information
V08b	Validations sur arrêt non déterminé (« Inconnu », ND, 999999)	5511 lignes, 0.0217 % des validations	information
V09	Part des validations à catégorie « identique »	84.460 % (4588169 lignes)	information
V09	Part des validations à catégorie « non_etablie »	0.850 % (377160 lignes)	information
V09	Part des validations à catégorie « probable »	10.210 % (333727 lignes)	information
V09	Part des validations à catégorie « variante_orthographique »	4.481 % (336498 lignes)	information
V10	Équivalence lda (2023 S1) et ID_ZDC (2023 S2), même arrêt et libellé	756 / 759 arrêts identiques	à examiner
V11	Valeurs plancher « 5 ou moins » (ancienne codification)	111917 lignes, 0.010 % des validations	information
V12	Arrêts portant plusieurs libellés	11 arrêts	information
F01	Jours fériés 2023	11 dates, 11 distinctes	conforme
F01	Jours fériés 2024	11 dates, 11 distinctes	conforme
F01	Jours fériés 2025	11 dates, 11 distinctes	conforme
F02	Dates fériées illisibles ou hors de l'année	0	conforme
M01	Unicité station × jour	52180 lignes, 52180 clés	conforme
M02	Codes qualité de TM : 1	52069 jours-station	information
M02	Codes qualité de TM : 9	5 jours-station	information
M02	Codes qualité de TM : absent	106 jours-station	information
M03	Codes qualité de RR : 1	49983 jours-station	information

Id	Contrôle	Mesure	Statut
M03	Codes qualité de RR : absent	2197 jours-station	information
M04	Incohérences TN > TX ou RR < 0	0 TN>TX, 0 RR<0	conforme
M05	Températures retenues hors de [-25 ; 45] °C	0	conforme
M06	Stations avec TM et RR retenus sur au moins 95 % des jours	44 / 50 stations	conforme
M07	Stations à plusieurs noms ou positions sur la période	0	conforme
Z01	Unicité de zdc_id	15597 lignes, 15597 identifiants	conforme
Z02	Zones sans coordonnées WGS84	0	conforme
Z03	Zones hors de l'emprise Île-de-France (lon 1,4–3,6 ; lat 48,1–49,3)	22	à examiner
G01	Unicité de dim_date.jour	1096 lignes, 1096 jours	conforme
G02	Unicité de dim_zone.zdc_id	15597 lignes, 15597 zones	conforme
G03	Unicité du grain de fait_validations_jour (jour × zone × catégorie)	5327245 lignes, 5327245 clés	conforme
G04	Conservation Silver -> fait (lignes source et somme NB_VALD)	lignes 5635554 -> 5635554 ; NB_VALD 5790213667 -> 5790213667	conforme
G05	Jointure validations -> dim_zone : non-correspondance en lignes	39095 / 5635554 lignes (0.694 %)	information
G06	Jointure validations -> dim_zone : non-correspondance en volume	29794437 / 5790213667 validations (0.515 %)	information
G07	Jointure fait -> dim_date : lignes sans date	0 / 5327245	conforme
G08	Unicité du grain ds_zone_jour (zone × jour)	819808 lignes, 819808 clés	conforme
G09	Conservation fait (zones référencées) -> ds_zone_jour	NB_VALD 5760419230 -> 5760419230	conforme
G10	Grille ds_zone_jour : jours observés	795430 / 819808 (97.03 %)	information
G11	Source de la météo dans ds_zone_jour	station 819250, repli IDF 558, indisponible 0	conforme
G12	Distance zone -> station de référence (zones avec validations)	médiane 3.9 km, max 23.9 km	information
G13	Stations de référence distinctes utilisées	39	information

Annexe B : scripts versionnés

Étape	Fichier
Configuration	`src/config.py`, `.env.example`
Collecte, validation	`src/collect/http.py`, `src/collect/validation.py`, `src/collect/sources.py`
Bronze	`src/bronze/storage.py`, `src/bronze/collecte.py`
Chargement Silver	`src/silver/normalisation.py`, `src/silver/chargement.py`
SQL Silver	`sql/silver/01_ref_categorie_titre.sql` à `05_meteo.sql`
SQL Gold	`sql/gold/01_dimensions.sql`, `02_faits.sql`, `03_kpi_et_semantique.sql`
Contrôles	`sql/checks/silver_validations.sql`, `silver_referentiels.sql`, `gold.sql`, `src/quality/checks.py`

Étape	Fichier
Enchaînement	`src/pipeline.py`, appelé par `notebooks/TD1_ADJAKOSSA_AKODEKOU.ipynb`
Tests	`tests/` (21 tests, sans réseau ni GCP)

Bibliographie

Etalab (2026). *API Jours fériés, zone métropole*. URL : https://calendrier.api.gouv.fr/jours-feries/metropole/2023.json (visité le 31/10/2026).

Google Cloud (2026a). *Query Cloud Storage data in external tables – BigQuery*. URL : https://cloud.google.com/bigquery/docs/external-data-cloud-storage (visité le 01/11/2026).

— (2026b). *Request preconditions – Cloud Storage*. URL : https://cloud.google.com/storage/docs/request-preconditions (visité le 01/11/2026).

Île-de-France Mobilités (2026a). *Données de validation : documentation (pièce jointe du jeu de données)*. URL : https://data.iledefrance-mobilites.fr/api/v2/catalog/datasets/histo-validations-reseau-ferre/attachments/donnees_de_validation_pdf (visité le 01/11/2026).

— (2026b). *Historique des validations sur le réseau ferré*. URL : https://data.iledefrance-mobilites.fr/explore/dataset/histo-validations-reseau-ferre/ (visité le 31/10/2026).

— (2026c). *Zones de correspondance*. URL : https://data.iledefrance-mobilites.fr/explore/dataset/zones-de-correspondance/ (visité le 31/10/2026).

Météo-France (2026a). *Descriptif des champs RR-T-Vent et des codes qualité (Q_descriptif_champs_RR-T-Vent.csv)*. URL : https://www.data.gouv.fr/datasets/donnees-climatologiques-de-base-quotidiennes (visité le 01/11/2026).

— (2026b). *Données climatologiques de base – quotidiennes*. URL : https://www.data.gouv.fr/datasets/donnees-climatologiques-de-base-quotidiennes (visité le 31/10/2026).

pyproj contributors (s. d.). *pyproj : interface Python de PROJ*. Version 3.8.0. URL : https://pyproj4.github.io/pyproj/.

TD1 – Données sources (2026). URL : https://www.m2bigdata.biz/td1/02-sources.html (visité le 31/10/2026).

TD1 – ETL des données de fréquentation IDFM sur GCS et BigQuery (2026). URL : https://www.m2bigdata.biz/td1/td1.html (visité le 31/10/2026).